


2020-2025 대화 음성 연구 인프라

찾고, 정렬하고, 직접 판정할 수 있게

공통 Jamo 발음사전 · MFA · 6-tier TextGrid · 검색용 CSV/Parquet · 연도별 복구



핵심 원칙: 자동 phone은 위치 안내다. 실제 실현 여부는 연구자가 듣고 본다.

인프라가 답해야 할 질문은 세 가지다

01

찾을 수 있는가

형태소·표기 환경·Roman·POS로
후보를 재현 가능하게 추출

02

바로 들을 수 있는가

utt_id로 WAV·TextGrid·동반표를
한 번에 모아 청취

03


판정을 섞지 않는가

원자료·자동 파생·연구자 판단의
출처를 분리

인프라의 성공 기준

“ㄴ 삽입이 실현됐다”를 자동 판정하는 것이 아니라, 그 판단에 필요한 발화·음성·정렬·환경을 빠
짐없이 연결하는 것.

자동화는 후보와 근거를 준비하고, 연구자는 실현을 판단한다



자동값의 지위

G2P·사전·MFA·wav2vec2는 서로 다른 출처의 보조값이다. 어느 열도 manual judgment를 덮어쓰지 않는다.

같은 “발음 정보”처럼 보여도 생성 주체와 해석 범위가 다르다

원자료

JSON original_form · 화자/대화 ID · 시간 · note

자동 수정 금지

연구자 정책/부착

6-tier 선택 · 형태소 전체-span · 선별 KOINA

방법 설계로 기록

기계 파생

Roman · 공통사전 phone · MFA interval · broad phoneme

출처와 버전 고정

수동 판정

실제 실현 여부 · 음향 근거 · 예외 처리

별도 표에 기록

논문에서 “누가·무엇으로·어떤 한계 아래 만들었는가”를 열 단위로 설명할 수 있어야 한다.

시간을 실제로 아는 층위와 발화 전체-span 참조층을 구분한다


words		혹시	요즘	
phones_mfa		ϕ ^w o k ə j	j o dʒ m	
phoneme_r_auto		H O G S S I	Y O J M	
utterance		혹시 요즘		
utterance_orth_r		H O k _ S S I Y O _ J E U m		
morph_analysis_utt		혹시/MAG 요즘/NNG		

0

모든 tier는 0-xmax를 연속 커버한다 · 형태소는 추정 시간분할하지 않는다

xmax

5.1M 개별 CSV 대신 연도별 정본 4종 + 후보 bundle 파생



gzip CSV = 감사·보존 정본 · Parquet = DuckDB/R/Python 검색 미러

분절음·음절·형태소·어절을 같은 구분자로 뭉개지 않는다

철자 Roman

2사람이 → <2> _ S A _ R A m _ l

비한글은 literal, 음절 내부는 _ 어절은 | — 발음 추정이 아니라 검색용 전자

형태소

혹시/MAG | 요즘/NNG

형태소 경계는 CSV/Parquet에서 위치 검색

좌표계

eojeol_idx

reference_eojeol_idx

mfa_word_idx

phone_interval_idx

원 형태소 어절 ≠ MFA reference 어절일 수 있다. 다름 자체를 provenance로 보존한다.

검색 주의: Roman은 대소문자 구분 — k/p/t(종성)와 K/P/T(격음)를 case-insensitive로 합치지 않는다.

“정렬된 phone”과 “실제로 들린 분절”은 같은 말이 아니다

MFA가 제공하는 것

- 공통사전/G2P phone을 음성 시간에 정렬
- 대략적인 분절 위치와 word interval
- 동일 모델·inventory 기반의 연도 간 기준
- 후보 청취 구간을 빠르게 찾는 출발점

MFA가 판정하지 않는 것

- L 삽입·경음화 등의 실제 실현 여부
- 사전형과 다른 음성 변이의 정답
- 형태소의 실제 음향 경계
- 음운론적 분석의 최종 결론

phoneme_r_auto = phones_mfa만을 넓은 Roman 범주로 기계 대응 · 기저형 역복원 아님

전수 기본층과 연구별 보조층을 분리해야 다시 쓸 수 있다

KOINA

운율 경계·억양 분석
후보 발화에만 실행

선별 실행

이어붙이기

같은 대화의 연속 맥락
원 utt_id·offset 보존

선별 실행

wav2vec2 phone

실제 음성 기반 보조 phone
MFA 열을 덮어쓰지 않음

선별 실행

공통 join key

utt_id + 원본 시간 + 이어붙인 offset + 분석 버전 → 어떤 보조값도 원자료와 분리해 재현

현상 판정은 뒤에서, 후보 공간은 앞에서 정교하게 만든다

후보 규칙

형태소/POS + 어절 위치 + 철자 Roman + 인접 분절 + 화자/대화 메타데이터

01 L 삽입

표기·형태소 환경으로 후보 추출 → 음성에서 실현 판정

02 경계 음운현상

어절/형태소 경계 양쪽 조건을 조합해 대조군 확보

03 발음 변이

사전·G2P·MFA·wav2vec2 차이를 후보 신호로만 사용

04 운율과 변이

선별 자료에 KOINA를 붙여 경계·억양과 함께 분석

자동 인프라는 “어디를 볼 것인가”를 답하고, 연구자는 “무엇이 실현되었는가”를 답한다.

문제 1건 때문에 연도 전체를 자동 --clean 재계산하지 않는다



재실행 계약

temp가 있으면 resume 1회 → 실패하면 체크포인트 보존·중단 → 원인 수정 후 같은 지점 재개. 전체 clean은 연구자 명시 승인만.

2026-08-01 최종 preflight: NO_GO — 고장이 아니라 승인 대기

NO_GO

자동 실행 금지 상태를 정확히 잡아냄

통과

- ✓ 공통 Jamo 사전·adoption SHA 검증
- ✓ D: DATA_SSD · 318.5 GiB 여유
- ✓ 2020–2025 원 세션 coverage 전수 통과
- ✓ Python 287/287 · PowerShell 20/20
- ✓ live lock·stale output 충돌 없음

남은 필수 승인

2020–2021
승인 제외 계약 없음

2022–2025
lab 입력 계약 생성 전
→ 따라서 승인 계약도 아직 없음

다음 단계는 MFA가 아니라 승인자료 생성이다.

승인자료 → 연구자 승인 → 재점검 GO → 연도 큐

1 승인 후보표 생성
(MFA 시작 안 함)

2 연도별 제외 후보
연구자 확인·승인

3 최종 preflight
status=GO 확인

4 무인 연도 큐 시작
정본 자동승격 안 함

① 승인자료 생성 명령

```
& ".\scripts\prepare_full_mfa_approval_reviews.ps1"
```

② 후보 확인 뒤: 승인 계약 → 전체 preflight → GO일 때만 연도 큐

```
& ".\scripts\start_full_mfa_after_review.ps1" -ApprovedBy "ari30"
```

1단계는 MFA·WAV 이동·자동 승인·정본 승격을 하지 않는다.

같은 기준으로 정렬하고, 다른 판단으로 남긴다

2020–2025 자료에 동일한 Korean MFA acoustic model, Jamo G2P, 공통 발음사전 및 phone inventory를 적용하였다. 원 전사·형태소 분석, MFA 입력 reference, 사전/G2P phone, MFA 정렬 phone, 자동 Roman을 별도 출처로 보존하였다. MFA phone은 청취 위치를 찾는 자동 강제 정렬 보조값이며, 실제 음운 실현은 선별 발화의 WAV와 TextGrid를 연구자가 검토해 별도로 판정하였다.

전수 실행 전 마지막 질문

모든 승인 계약이 입력 계약 ID와 묶였는가? → GO일 때만 시작한다.